# Introduzione agli algoritmi

# Leonardo Ganzaroli

# Indice

	Intr	roduzione	1
1	Noz	zioni di base	4
	1.1	Alcune definizioni	4
	1.2	Modello del calcolatore	5
		1.2.1 Memoria centrale/primaria	5
		1.2.2 Memoria secondaria	6
		1.2.3 Random Access Machine	6
	1.3	Criterio della misura	6
<b>2</b>	Alg	oritmi	7
_	2.1	Notazione asintotica	7
		2.1.1 Algebra	9
	2.2	Valutazione del costo	9
	2.3		11
			12
	2.4		15
			15
		1	16
	2.5		17
			17
			19
			24
3	Stri	utture dati	26
U	3.1		26
	3.2		27
	0.2		27
			$\frac{27}{27}$
	3.3		28
	5.5		28
	3.4	<u>.</u>	28
	3.5		29

3.6	Albero															30
	3.6.1	Binario														31
	3.6.2	Неар														32
	3.6.3	ABR														32
	3.6.4	Rosso-ne	$_{ m ro}$													33
3.7	Dizion	ario														34
	3.7.1	Indirizza	ment	to	dir	ett	Ю									35
	3.7.2	Hash														35

# Introduzione

Questi appunti sono derivanti principalmente dalle dispense del corso di *Introduzione agli algoritmi* che ho svolto durante la laurea Triennale di informatica all'università "La Sapienza".

## 1 Nozioni di base

#### 1.1 Alcune definizioni

**Definizione** L'informatica è la scienza che consente di ordinare, trattare e trasmettere l'informazione attraverso l'elaborazione elettronica.

Una definizione alternativa è L'informatica è la scienza degli algoritmi che descrivono e trasformano l'informazione: la loro teoria, analisi, progetto, efficienza, realizzazione e applicazione.

**Definizione** Una struttura dati è un metodo per organizzare dati che prescinde dai dati stessi.

**Definizione** Un algoritmo è una sequenza di comandi elementari ed univoci che terminano in un tempo finito ed operano su strutture dati.

**Definizione** L'efficienza di un algoritmo è la quantificazione delle sue esigenze in termini di spazio e tempo.

**Definizione** Il problem solving è un'attività atta a raggiungere una soluzione partendo da una situazione iniziale, in questo contesto è limitata ai problemi computazionali.

**Definizione** Un problema computazionale è un problema che richiede di descrivere in modo automatico la relazione tra un insieme di valori di input e un insieme di valori di output.

**Definizione** Un algoritmo si dice corretto se per ogni istanza di un certo problema esso termina producendo sempre l'output corretto.

#### 1.2 Modello del calcolatore

Per poter calcolare i vari costi di un algoritmo è necessario usare un modello astratto di calcolatore, si può modellare con 4 elementi:

- Processore
- Memoria centrale
- Memoria secondaria
- Dispositivi I/O

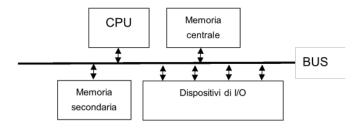


Figura 1: Connessione tra gli elementi

## 1.2.1 Memoria centrale/primaria

In questo caso ci si concentra sulla RAM (Random access memory) che può essere vista come una lunga sequenza di componenti elementari detti bit che possono assumere solo i valori 0 e 1.

Definizione Un gruppo di 8 bits è detto byte.

**Definizione** Un registro/parola di memoria è un aggregato di bytes, nei calcolatori moderni sono normalmente 4 o 8.

#### Inoltre:

- Il processore può operare su un registro (sia in lettura che scrittura) in una sola operazione
- Ogni parola ha un indirizzo
- Il tempo per svolgere un'operazione è lo stesso indipendentemente dall'indirizzo
- Un indirizzo è un numero intero

**Definizione** Lo spazio di indirizzamento è il numero di bit usati per rappresentare gli indirizzi.

#### 1.2.2 Memoria secondaria

La memoria secondaria ha le seguenti caratteristiche:

- Conserva il contenuto
- È più lenta di quella centrale
- È più grande di quella centrale
- È più economica di quella centrale

#### 1.2.3 Random Access Machine

Questo modello teorico astratto è caratterizzato da una memoria ad accesso casuale, un solo processore ed un insieme di istruzioni eseguite in tempo costante che permettono di fare:

- I/O
- Operazioni aritmetiche
- Accesso e modifica del contenuto della memoria
- Salti

#### 1.3 Criterio della misura

**Definizione** Il costo computazionale di un algoritmo è il suo tempo di esecuzione e/o le sue necessità in termini di memoria.

#### Costo uniforme (Quello usato)

Si parla di costo uniforme se si assume che il costo di esecuzione dipende dalla dimensione degli operandi, ogni operazione è un singolo passo con costo 1.

#### Costo logaritmico

Si parla di costo logaritmico se si assume che il costo delle operazioni elementari è in funzione della dimensione degli operandi  $(n \to \log n)$ .

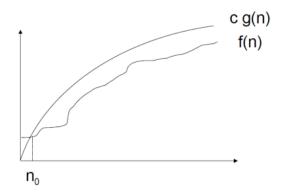
# 2 Algoritmi

## 2.1 Notazione asintotica

**Definizione** Per efficienza asintotica degli algoritmi si intende la valutazione del loro costo quando l'input è sufficientemente grande.

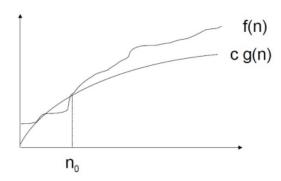
**Definizione** Date  $f(n), g(n) \ge 0$ . Si dice che f(n) è un O(g(n)) se:

$$\exists c, n_0 \mid \forall \ n \ge n_0 \ 0 \le f(n) \le c * g(n)$$



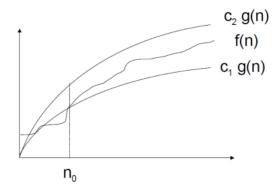
**Definizione** Date  $f(n), g(n) \ge 0$ . Si dice che f(n) è un  $\Omega(g(n))$  se:

$$\exists c, n_0 \mid \forall \ n \geq n_0 \ f(n) \geq c * g(n)$$



**Definizione** Date  $f(n), g(n) \ge 0$ . Si dice che f(n) è un  $\Theta(g(n))$  se:

$$\exists c_1, c_2, n_0 \mid \forall \ n \ge n_0 \ c_1 * g(n) \le f(n) \le c_2 * g(n)$$



Quindi f(n) deve essere sia  $\Omega(g(n))$  che O(g(n)).

Esempio:

- $n^2 + 4n$  è  $O(n^2)$ Infatti se  $c \ge 5$  si ha che  $\forall n \ n^2 + 4n \le c * n^2$ .
- $2n^2+3$  è  $\Omega(n^2)$ Infatti se  $c\leq 2$  si ha che  $\forall~n~2n^2+3\geq c*n^2.$
- $(n+10)^3$  è  $\Theta(n^3)$ Per  $\Omega$  basta prendere  $n_0=c=1$ , per O invece  $n_0=10, c=8$ .

#### Calcolo alternativo

Un altro modo per determinare la notazione di una funzione è tramite i limiti, infatti si può usare il risultato di  $\lim_{n\to\infty}\frac{f(n)}{g(n)}$ :

$$\bullet \ > 0 \to f(n) = \Theta(g(n))$$

$$\bullet = \infty \to f(n) = \Omega(g(n))$$

$$\bullet = 0 \to f(n) = O(g(n))$$

## 2.1.1 Algebra

Si possono seguire delle semplici regole che permettono di semplificare il calcolo del costo computazionale:

• Costanti moltiplicative

$$\forall k > 0, f(n) \ge 0$$
:

- Se f(n) è O(g(n)) allora k \* f(n) è O(g(n))
- Se f(n) è  $\Omega(g(n))$  allora k \* f(n) è  $\Omega(g(n))$
- Se f(n) è  $\Theta(g(n))$  allora k\*f(n) è  $\Theta(g(n))$
- Commutatività somma

$$\forall f(n), d(n) > 0$$
:

- Se f(n) è O(g(n)) e d(n) è O(h(n)) allora f(n) + d(n) = O(g(n) + h(n)) = O(max(g(n), h(n)))
- Se f(n) è  $\Omega(g(n))$  e d(n) è  $\Omega(h(n))$  allora  $f(n)+d(n)=\Omega(g(n)+h(n))=\Omega(\max(g(n),h(n)))$
- Se f(n) è  $\Theta(g(n))$  e d(n) è  $\Theta(h(n))$  allora  $f(n)+d(n)=\Theta(g(n)+h(n))=\Theta(\max(g(n),h(n)))$
- Commutatività prodotto

$$\forall f(n), d(n) > 0$$
:

- Se f(n) è O(g(n)) e d(n) è O(h(n)) allora f(n)\*d(n) = O(g(n)\*h(n))
- Se f(n) è  $\Omega(g(n))$  e d(n) è  $\Omega(h(n))$  allora  $f(n)*d(n) = \Omega(g(n)*h(n))$
- Se f(n) è  $\Theta(g(n))$  e d(n) è  $\Theta(h(n))$  allora  $f(n)*d(n) = \Theta(g(n)*h(n))$

Esempio:

$$3n2^{n} + 4n^{4} = \Theta(n)\Theta(2^{n}) + \Theta(n^{4}) = \Theta(n2^{n}) + \Theta(n^{4}) = \Theta(n2^{n})$$

## 2.2 Valutazione del costo

**Definizione** Lo pseudocodice è un linguaggio di programmazione informale, esso ha le seguenti caratteristiche:

- Contiene tutti i costrutti di controllo classici
- Usa il linguaggio naturale per specificare le operazioni
- Ignora la gestione degli errori

## Alcune regole:

- Le istruzioni elementari hanno costo  $\Theta(1)$
- L'istruzione if ha costo pari alla somma di:
  - Costo della verifica della condizione
  - Massimo costo dei due rami
- I cicli hanno costo pari alla somma di:
  - Costo della verifica della condizione
  - Somma dei costi massimi di ogni iterazione
- Il costo totale è la somma dei costi di tutte le istruzioni

In alcuni casi non sarà possibile avere un unico risultato preciso, in quel caso si identificano:

- Caso migliore
- caso peggiore
- Caso medio (spesso difficile da calcolare)

#### Esempio:

```
Algorithm 1 Trovare l'elemento massimo di un array
  Trova_max(A):
  n = len(A)-1
                                                                                                        \triangleright \Theta(1)
  \max = A[0]
                                                                                                        \triangleright \Theta(1)
                                                                          \triangleright (n-1) iterazioni +\Theta(1)
  for i \in [1, n] do
       if A[i]>max then
                                                                                                        \triangleright \Theta(1)
            \max = A[i]
                                                                                                        \triangleright \Theta(1)
        end if
  end for
  return max
                                                                                                        \triangleright \Theta(1)
```

Il costo è 
$$T(n) = \Theta(1) + [(n-1) * \Theta(1) + \Theta(1)] + \Theta(1) = \Theta(n)$$

#### 2.3 Ricorsione

**Definizione** Un algoritmo è detto ricorsivo quando si esprime in termini di se stesso.

**Definizione** Una funzione è detta ricorsiva quando nel suo corpo è presente una chiamata alla funzione stessa.

**Definizione** Il caso base è quello che permette di terminare la ricorsione, ogni funzione ne deve avere almeno 1.

Il fattoriale è una funzione ricorsiva definita come:

$$n! = \begin{cases} 1 & \text{se } n = 0\\ n * (n-1)! & \text{altrimenti} \end{cases}$$

Trasformandola in algoritmo:

```
Algorithm 2 Fattoriale (ricorsivo)
```

```
Fatt(x):

if x==0 then 
ightharpoonup Caso base

return 1

end if

return x*Fatt(x-1)
```

Nel caso appena visto la ricorsione è definita diretta, si dice indiretta quando una funzione A chiama una funzione B e a sua volta B chiama A.

Un certo problema che si può risolvere tramite ricorsione è risolvibile anche in modo iterativo e viceversa, ovviamente quale approccio usare dipende dal caso specifico ma conviene sempre scegliere la soluzione che risulta più semplice e chiara. L'unico caso in cui conviene sempre usare l'approccio iterativo è quando bisogna tener conto dell'efficienza, infatti ogni chiamata di funzione occuperà una certa quantità di memoria e questo diventa un problema se le chiamate sono molte.

## 2.3.1 Equazioni di ricorrenza

Per calcolare il costo delle funzioni ricorsive bisogna riscrivere l'equazione trasformandola in una equazione di ricorrenza che ha la forma:

- Formulazione ricorsiva
- Caso base

La funzione fattoriale vista prima diventa:

$$T(n) = T(n-1) + \Theta(1)$$
chiamata ricorsiva + costo moltipicazione 
$$T(0) = \Theta(1)$$
 caso base

Per trovare il costo effettivo esistono diversi metodi:

- Di sostituzione
- Iterativo
- Dell'albero
- Principale

#### Metodo di sostituzione

L'idea di base è:

- Ipotizza una soluzione
- Verificala tramite induzione

Provo a trovare il costo della funzione del fattoriale ricorsiva:

• Ipotizzo che:

$$-T(n) = T(n-1) + c$$
 per qualche  $c > 0$ 

- -T(0) = d per qualche d > 0
- Provo con  $T(n) = O(n) \to T(n) \le kn$

Caso base:

$$T(0) \le k \iff k \ge d$$

Passo induttivo:

Assumendo che  $\forall r < n \quad T(r) \leq kr$ :

$$(T(n) \le k(n-1) + c = kn - k + c \le kn) \iff k \ge c$$

Ovviamente un valore k maggiore sia di c che di d esiste sempre, quindi T(n) è O(n) ed in modo analogo si verifica che T(n) è O(n), quindi O(n), quindi O(n).

#### Metodo iterativo

L'idea di base è quella di sviluppare l'equazione ed esprimerla come una somma di termini dipendenti da n e dal caso base.

Usando nuovamente la formula del fattoriale:

$$\begin{split} T(n) &= T(n-1) + \Theta(1) \\ &= T(n-2) + \Theta(1) + \Theta(1) \\ &= T(n-3) + \Theta(1) + \Theta(1) + \Theta(1) \end{split}$$

Continuando si arriva a  $T(n) = n\Theta(1) = \Theta(n)$ .

#### Metodo dell'albero

Si costruisce l'albero di ricorrenza in modo da valutare lo sviluppo del costo graficamente.

Data  $2T(\frac{n}{2}) + \Theta(n^2), T(1) = \Theta(1)$ :

- 1. radice:  $\Theta(n^2)$
- 2.  $2((\frac{n}{2})^2) = \Theta(\frac{n^2}{2})$
- 3.  $4((\frac{n}{4})^2) = \Theta(\frac{n^2}{4})$

L'i-esimo livello è  $2^{i-1}\Theta((\frac{n}{2^{i-1}})^2) = \Theta(\frac{n^2}{2^{i-1}})$ , il valore massimo di i deve essere tale che  $\frac{n}{2^{i-1}} = 1$ , ossia  $i-1 = \log n \to i = \log n + 1$ .

Il totale è 
$$\sum_{i=1}^{\log n+1}\Theta(\frac{n^2}{2^{i-1}})=n^2\sum_{j=0}^{\log n}\Theta(\frac{1}{2^j})=\Theta(n^2)$$

#### Metodo del teorema principale

Questo è il metodo più utile e fornisce la soluzione delle equazioni con forma:

$$T(n) = aT(\frac{n}{b}) + f(n)$$
$$T(1) = \Theta(1)$$

Con  $a \ge 1, b > 1$  e f(n) funzione asintoticamente positiva.

Ci sono 3 casi:

- Se  $f(n) = O(n^{\log_b a \epsilon})$  per qualche  $\epsilon > 0$  allora  $T(n) = \Theta(n^{\log_b a})$
- Se  $f(n) = \Theta(n^{\log_b a})$  allora  $T(n) = \Theta(n^{\log_b a} \log n)$
- Se  $f(n)=\Omega(n^{\log_b a+\epsilon})$  per qualche  $\epsilon>0,$   $f(\frac{n}{b})\leq c*f(n)$  per qualche c<1 ed n abbastanza grande allora  $T(n)=\Theta(f(n))$

#### Esempio:

- $9T(\frac{n}{3}) + \Theta(n)$ Primo caso,  $n^{\log_3 9} = n^2 \to \Theta(n^2)$ .
- $T(\frac{2n}{3}) + \Theta(1)$ Secondo caso,  $n^{\log_{\frac{3}{2}} 1} = 1 \to \Theta(\log n)$ .
- $T(3\frac{n}{4}) + \Theta(n\log n)$ Si ha  $n^{\log_4 3} \approx n^{0,7}$ , aggiungendo  $\epsilon = 0, 2$  si è nel terzo caso. Ponendo  $c = \frac{3}{4}$  si ottiene  $\frac{3n}{4}\log \frac{n}{4} \leq \frac{3n}{4}\log n$  che risulta vero, quindi  $T(n) = \Theta(n\log n)$ .

## 2.4 Alg. di ricerca

Uno dei problemi più diffusi è quello della ricerca di un elemento in un insieme di dati (in questo caso un array), esistono 2 algoritmi diversi che assolvono a questo compito.

#### 2.4.1 Sequenziale

La ricerca sequenziale è quella più semplice e l'unica alternativa se l'array non è ordinato, si controlla ogni elemento presente:

#### Costi:

- Caso peggiore O(n)
- Caso migliore O(1)
- Costo medio:

Ipotizzando che un elemento x si possa trovare in ogni posizione con la stessa probabilità  $(\frac{1}{n})$ , il numero medio di iterazioni sarà  $\sum_{i=1}^{n} i * \frac{1}{n} = \frac{n+1}{2}$  che diventa O(n).

#### 2.4.2 Binaria

Nel caso in cui l'array sia ordinato si può cercare in modo simile a come si cerca una parola nel dizionario, si controlla l'elemento centrale e in base al suo valore si continua la ricerca nel sottoarray sinistro o destro.

## Algorithm 4 Ricerca binaria

```
\begin{aligned} &\operatorname{Trova}(A, x) \colon \\ &a,b = 0, \operatorname{len}(A) \\ &m = \frac{a+b}{2} \\ &\text{while } A[m]! = x \text{ do} \\ &\text{ if } A[m] > x \text{ then} \\ &b = m-1 \\ &\text{ else} \\ &a = m+1 \\ &\text{ end if} \\ &\text{ if } a > b \text{ then} \\ &\text{ return } -1 \\ &\text{ end if} \\ &m = \frac{a+b}{2} \\ &\text{ end while} \end{aligned}
```

In questo caso ad ogni iterazione si vanno a dimezzare gli elementi su cui lavorare, questo porta il numero di iterazioni necessarie ad avere una crescita logaritmica ( $\log n$ ).

#### Costi:

- Caso peggiore  $O(\log n)$
- Caso migliore O(1)

Come visto prima si può calcolare il caso medio, ipotizzo che:

- $\bullet$  x è presente
- x si può trovare in ogni posizione con la stessa probabilità  $(\frac{1}{n})$
- len(Array) = potenza del 2 (per semplicità di calcolo)

Nell'i-esima iterazione sono raggiungibili  $n(i) = 2^{i-1}$  elementi, quindi si eseguono i iterazioni solo se x è uno degli elementi raggiunti in quella iterazione e la probabilità che sia in quegli elementi è  $\frac{n(i)}{n}$ .

Il numero di iterazioni è  $\frac{1}{n}\sum_{i=1}^{\log n}i2^{i-1}=\log n-1+\frac{1}{n}$  che diventa  $O(\log n).$ 

## 2.5 Alg. di ordinamento

Un altro problema molto diffuso è quello dell'ordinamento di un insieme di dati (anche in questo caso si considera un array/vettore) rispetto ad una certa relazione d'ordine sullo stesso.

La maggior parte degli algoritmi che verranno presi in esame sono basati su:

- Scambio tra 2 elementi
- Confronto tra 2 elementi

**Definizione** I dati satellite sono eventuali dati aggiuntivi collegati ad un elemento.

#### 2.5.1 Semplici

#### **Insertion Sort**

Questo algoritmo si basa sul prendere un elemento e spostarlo a sinistra fino a trovargli una posizione adatta:

## ${\bf Algorithm~5}~{\rm Insertion~Sort}$

```
\begin{array}{l} \text{Ins.sort}(A) \colon \\ \textbf{for } j \in [1, \operatorname{len}(A) - 1] \ \textbf{do} \\ & x = A[j] \\ & i = j - 1 \\ & \textbf{while } (i \geq 0) \ \& \ (A[i] > x) \ \textbf{do} \\ & A[i + 1] = A[i] \\ & i - - \\ & \textbf{end while} \\ & A[i + 1] = x \\ \textbf{end for} \end{array}
```

#### Costi:

- Caso migliore = O(n)Gli elementi sono ordinati ed il secondo ciclo non viene eseguito.
- Caso peggiore = O(n²)
   Gli elementi sono ordinati in senso inverso, in questo caso ogni elemento va spostato lungo tutto l'array e questo porta ogni iterazione ad un costo n\*n.

#### **Selection Sort**

Questo algoritmo si basa sul trovare ad ogni iterazione il minimo/massimo elemento nell'array ancora disordinato e spostarlo in prima/ultima posizione:

#### Algorithm 6 Selection Sort

```
\begin{array}{l} \operatorname{Sel\_sort}(A) \colon \\ \mathbf{for} \ i \in [0, \operatorname{len}(A) - 2] \ \mathbf{do} \\ & \operatorname{min} = \mathbf{i} \\ \mathbf{for} \ j \in [i+1, \operatorname{len}(A) - 1] \ \mathbf{do} \\ & \mathbf{if} \ A[\mathbf{j}] \! < \! A[\mathbf{m}] \ \mathbf{then} \\ & \mathbf{m} = \mathbf{j} \\ & \mathbf{end} \ \mathbf{if} \\ & \mathbf{end} \ \mathbf{for} \\ & \operatorname{Scambia} \ A[\mathbf{i}] \ \mathbf{e} \ A[\mathbf{m}] \\ & \mathbf{end} \ \mathbf{for} \\ \end{array}
```

Questo algoritmo esegue entrambi i cicli ad ogni iterazione indipendentemente dalla distribuzione dei dati, questo lo porta ad avere il costo unico  $\Theta(n^2)$ .

#### **Bubble Sort**

Questo algoritmo confronta le coppie adiacenti ed eventualmente ne scambia gli elementi finché non sono tutte ordinate:

#### Algorithm 7 Bubble Sort

```
Bub_sort(A):

for i \in [0, len(A) - 2] do

for j \in [i + 1, len(A) - 1] do

if A[j] < A[i] then

Scambia A[i] \in A[j]

end if

end for

end for
```

Come per l'algoritmo precedente anche qui i 2 cicli vengono eseguiti in qualunque caso, il costo è lo stesso.

#### 2.5.2 Efficienti

**Definizione** L'albero di decisione rappresenta graficamente le possibili strade che un algoritmo basato su ordinamento può percorrere.

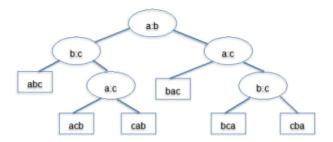


Figura 2: Albero con 3 elementi

Passando ad un livello più generale è vero che:

- $\bullet\,$  Un array lungo nha n!possibili ordinamenti
- $\bullet\,$  Un albero alto h ha al massimo  $2^h$  foglie

h deve essere tale che  $2^h \ge n! \Rightarrow h \ge \log n! = \Theta(n \log n)$ , quindi il costo minimo di un algoritmo basato sugli ordinamenti è  $\Omega(n \log n)$ .

## Mergesort

Questo algoritmo è basato sulla tecnica divide et impera, ossia divide il problema in sottoproblemi e li risolve ricorsivamente (ogni chiamata riceve metà dell'array ed ordina i sottoarray):

## Algorithm 8 Mergesort

```
Mer\_sort(A,index,index2):
if index<index2 then
   m = \frac{index + index2}{2}
   Mer_sort(A,index,m)
   Mer\_sort(A,m+1,index2)
   Fondi(A,index,m,index2)
end if
Fondi(A,index,m,index2):
                                            ⊳ Combina i 2 sottoarray in uno
i,j=index,m+1
B=[]
while (i \le m) \& (j \le index2) do
   if A[i] \leq A[j] then
      B.append(A[i])
      i++
   {f else}
      B.append(A[j])
      j++
   end if
end while
while i \le m do
   B.append(A[i])
   i++
end while
while j≤index2 do
   B.append(A[j])
   j++
end while
for i \in [0, len(B) - 1] do
   A[index+i]=B[i]
end for
```

La funzione Fondi ha costo  $\Theta(n)$  dato che tutti i cicli scorrono al più l'intero array, quindi O(n) + O(n) + O(n) + O(n), la funzione principale si può esprimere con l'equazione di ricorrenza:

$$T(n) = 2T(\frac{n}{2}) + \Theta(n)$$
$$T(1) = \Theta(1)$$

Che una volta risolta diventa  $\Theta(n \log n)$ .

#### Merge-Insertion

Quando la dimensione dei sottoproblemi diventa abbastanza piccola l'Insertion Sort risulta più veloce del Mergesort, combinandoli si ottiene:

## Algorithm 9 Merge\_Insertion

```
\begin{split} & \operatorname{MerIns\_sort}(A, \operatorname{index}, \operatorname{index}2, k, \operatorname{dim}) \colon \\ & \operatorname{if dim} > k \ \operatorname{then} \\ & \operatorname{m} = \frac{\operatorname{index} + \operatorname{index}2}{2} \\ & \operatorname{MerIns\_sort}(A, \operatorname{index}, \operatorname{m}, k, \operatorname{m-index} + 1) \\ & \operatorname{MerIns\_sort}(A, \operatorname{m} + 1, \operatorname{index}2, k, \operatorname{index}2 - \operatorname{index}) \\ & \operatorname{Fondi}(A, \operatorname{index}, \operatorname{m}, \operatorname{index}2) \\ & \operatorname{else} \\ & \operatorname{Ins\_Sort}(\operatorname{index}, \operatorname{index}2) \\ & \operatorname{end} \ \operatorname{if} \end{split}
```

L'equazione è:

$$T(n) = 2T(\frac{n}{2}) + \Theta(n)$$
$$T(k) = \Theta(k^{2})$$

Se  $k = O(\log n)$  il costo dell'algoritmo diventa  $\Theta(n \log n)$ .

#### Quicksort

Anche questo algoritmo sfrutta il *divide et impera*, la differenza sta nell'uso di un *pivot* per dividere in sottoarray:

## Algorithm 10 Quicksort

```
Quick_sort(A,index,index2):
if index<index2 then
   m=Partiziona(A,index,index2)
   Mer\_sort(A,index,m-1)
   Mer_sort(A,m+1,index2)
end if
Partiziona(A,index,index2):
                                                      ▷ "Crea" i sottoarray
pivot=A[index]
                                 ▷ Come si sceglie il pivot non è importante
i=index+1
for j \in [1 + index, index2 + 1] do
   if A[j]<pivot then
      scambia A[i]e A[j]
      i++
   end if
end for
scambia A[i-1] e A[index]
return i-1
```

Si nota facilmente che Partiziona ha costo  $\Theta(n)$ , con questa informazione si può scrivere l'equazione di ricorrenza:

$$T(n) = T(k) + T(n - k - 1) + \Theta(n) \text{ con } 0 \le k \le n - 1$$
  
 $T(1) = \Theta(1)$ 

Valutando i 3 possibili casi ottengo i costi:

• Migliore: Sottoproblemi sempre bilanciati

$$2T(\frac{n-1}{2}) + \Theta(n) = \Theta(\log n)$$

• Peggiore: Un sottoproblema è sempre nullo

$$T(n-1) + \Theta(n) = \Theta(n^2)$$

• Medio: Il pivot suddivide gli elementi con egual probabilità

$$\frac{1}{n-1} \left[ \sum_{k=0}^{n-1} (T(k) - T(n-k)) \right] + \Theta(n) = \Theta(n \log n)$$

## Heapsort

Questo algoritmo trasforma l'array in un Max-Heap e sfrutta le sue caratteristiche, ad ogni iterazione scambia la radice con l'ultima foglia e risistema l'heap escludendo ad ogni iterazione l'ultima foglia:

## Algorithm 11 Heapsort

```
Heap\_sort(A):
Trasforma A in heap
                                                                             \triangleright O(n \log n)
for x \in [len(A) - 1, 1] do
    Scambia A[0] e A[x]
    Heapify(A,0,x)
end for
Heapify(A,i,size):
                                                                      ▶ Aggiusta l'heap
l,r,max = 2i + 1, 2i + 2, i
if (l < size) & (A[l] > A[i]) then
    \max = 1
end if
if (r \le size) \& (A[r] > A[max]) then
    \max = r
end if
\mathbf{if} \ \mathrm{max!} {=} \mathrm{i} \ \mathbf{then}
    Scambia A[max] e A[i]
    Heapify(A, max, size)
end if
```

Il costo totale è  $T(n) = O(n) + O((n-1)\log n) = O(n\log n)$ 

#### 2.5.3 Lineari

I 2 algoritmi che verranno presi in considerazione hanno un costo lineare perché non sono basati su confronti.

#### **Counting Sort**

end while

end for

Ipotizzando che l'array contenga solamente numeri interi compresi in un certo range [0, k], creo un array ausiliario di lunghezza k in cui conto le occorrenze di ogni numero e vado poi a sovrascrivere l'array originale:

```
Algorithm 12 Counting Sort

Count_sort(A):

C=Array di lunghezza \max(A)+1

for i \in [0, \operatorname{len}(A)-1] do

C[A[i]]++
end for

j=0

for i \in [0, \max(A)] do

while C[i]>0 do

A[j]=i
j++
C[i]--
```

Il costo è dato dalla somma dei due cicli  $\Theta(n+k)$ , se  $k=O(n)\Rightarrow \Theta(n)$ .

Una cosa da tenere in considerazione è la dimensione dell'array ausiliario, infatti in casi come  $A = \{4,6,1,2,55555\}$  C occuperà inutilmente una grande quantità di memoria.

#### Con dati satellite

Dato che l'array originale viene sovrascritto bisogna implementare delle modifiche per preservare eventuali dati satellite:

## Algorithm 13 Counting Sort con dati satellite

```
Count_sort2.0(A):
C=Array \ di \ lunghezza \ max(A)+1
B=Array \ di \ lunghezza \ len(A)
 for \ i \in [0, len(A)-1] \ do
 C[A[i]]++
 end \ for
 for \ i \in [1, max(A)] \ do
 C[i]+=C[i-1]
 end \ for
 for \ i \in [len(A), -1] \ do
 B[C[A[j]]]=A[j]
 C[A[j]]--
 end \ for
 return \ B
```

#### **Bucket Sort**

In questo caso presumo che gli elementi siano equamente distribuiti nell'intervallo [1, k], divido l'intervallo in sottointervalli detti bucket di ampiezza uguale che verranno ordinati con un altro algoritmo e ricombinati alla fine:

## Algorithm 14 Bucket Sort

```
Buck_sort(A):

Crea i bucket in base a \max(A) \triangleright Bucket=Lista for i \in [0, \operatorname{len}(A) - 1] do

Inserisci A[i] nell'apposito bucket
end for
for i \in [0, \operatorname{len}(A) - 1] do

Ordina l'i-esimo bucket
end for

Combina i bucket (seguendo l'ordine B_1, B_2, \ldots) in un'unica lista
Copia la lista in A
```

Il costo dipende da:

- Distribuzione dei numeri nei bucket
- Numero e lunghezza dei bucket
- Algoritmo di ordinamento usato

In ogni caso il costo medio è  $O(n+k+\frac{n^2}{k})$  che diventa lineare se k=n.

## 3 Strutture dati

Una struttura dati memorizza e manipola insiemi dinamici di dati varianti nel tempo, ogni elemento (o nodo) può poi essere composto da molteplici dati elementari, comunemente sono composti da:

- Chiave: usata per distinguere gli elementi
- Dati satellite: altri dati non usati direttamente

Le tipiche operazioni che si possono svolgere sono:

- Ricerca di un elemento
- Ricerca del minimo/massimo
- Ricerca dell'elemento precedente/successivo
- Inserimento di un nuovo elemento
- Cancellazione di un elemento

## 3.1 Array

Un array ha le seguenti caratteristiche:

- Ogni elemento è omogeneo
- Ha l'accesso casuale
- Ha dimensione fissa

Array	Ricerca	Min/Max	Prec/Succ	Inserimento	Cancellazione		
generico	O(n)	$\Theta(n)$	$\Theta(n)$	$\Theta(1)$	$\Theta(1)$		
ordinato	$O(\log n)$	$\Theta(1)$	$\Theta(1)$	O(n)	O(n)		

## 3.2 Lista

**Definizione** Un puntatore è una variabile che contiene l'indirizzo in memoria di un'altra variabile.

**Definizione** Una lista è una struttura dati che organizza i suoi elementi in sequenza, le sue proprietà sono:

- L'accesso è solo sequenziale
- L'accesso avviene all'inizio o alla fine della lista

#### 3.2.1 Semplice

In questo caso un nodo conterrà un puntatore all'elemento successivo:



## 3.2.2 Doppia

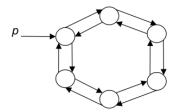
Per diminuire il costo della cancellazione si può inserire nel nodo anche un puntatore all'elemento precedente:



Lista	Ricerca	Min/Max	Prec/Succ	Inserimento	Cancellazione
semplice	O(n)	$\Theta(n)$	$\Theta(n)$	$\Theta(1)$	O(n)
doppia	O(n)	$\Theta(n)$	$\Theta(n)$	$\Theta(1)$	$\Theta(1)$

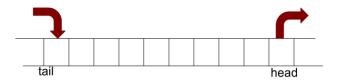
#### Circolare

Un'implementazione particolare è quella in cui l'ultimo elemento viene fatto puntare al primo creando così un cerchio:



## 3.3 Coda

**Definizione** La coda è una struttura con comportamento *FIFO*, ossia gli elementi vengono prelevati (operazione Dequeue) nell'ordine con cui sono stati inseriti (operazione Enqueue), ha una struttura:



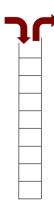
Coda	Enqueue	Dequeue
	$\Theta(1)$	$\Theta(1)$

#### 3.3.1 Con priorità

Una variante è quella in cui la posizione di un elemento non dipende dall'istante di inserimento ma da un altro valore detto di priorità (contenuto nel nodo). Un potenziale problema di questa variante è quello della *starvation* in cui un elemento non verrà mai estratto se viene scavalcato in continuazione da nuovi elementi con più priorità.

## 3.4 Pila

**Definizione** La pila è una struttura con comportamento *LIFO*, ossia gli elementi vengono prelevati (operazione Pop) nell'ordine inverso con cui sono stati inseriti (operazione Push), ha una struttura:



$$\begin{array}{c|cc} Pila & Pop & Push \\ \hline & \Theta(1) & \Theta(1) \end{array}$$

## 3.5 Grafo

**Definizione** Un grafo è una coppia di insiemi (V, E) tali che:

- $\bullet~V$ è un insieme di nodi
- $\bullet \ E \subseteq V \times V$ è un insieme di archi tra i nodi

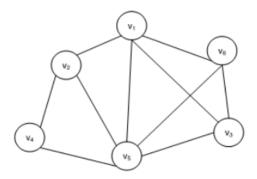


Figura 3: Esempio di Grafo

**Definizione** Un cammino è una sequenza di nodi  $(v_1,v_2,\ldots,v_k)\mid \forall \ i\ 1\leq i\leq k-1\ \exists (v_i,v_{i+1})\in E.$ 

Definizione Un ciclo è un cammino che inizia e finisce sullo stesso nodo.

Definizione Un grafo è detto aciclico se non contiene cicli.

**Definizione** Un grafo è detto connesso se esiste un cammino tra ogni coppia di nodi.

#### 3.6 Albero

Definizione Un albero è un grafo connesso e aciclico.

**Definizione** Un albero radicato è un albero in cui è presente un elemento chiamato *radice*, si rappresenta graficamente mettendo la radice in alto e rappresentando i cammini verso il basso organizzandoli a livelli:

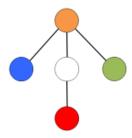


Figura 4: Esempio di albero

**Definizione** Il padre di un nodo x è il nodo che si incontra prima di lui nel cammino dalla radice, viceversa si dice figlio di x.

Definizione I nodi con lo stesso padre si chiamano fratelli.

**Definizione** L'antenato di un nodo x è qualsiasi nodo incontrato sul cammino per raggiungere x.

**Definizione** I discendenti di un nodo x sono tutti i nodi che hanno come antenato x.

Definizione Un nodo senza figli si chiama foglia.

**Definizione** L'altezza di un albero radicato è la lunghezza del cammino più lungo dalla radice ad una foglia.

**Definizione** Un albero radicato è detto ordinato se tutti i figli di ogni nodo hanno un qualche ordine.

#### 3.6.1 Binario

**Definizione** Un albero binario è un albero radicato e ordinato in cui ogni nodo ha al massimo 2 figli definiti sinistro e destro.

**Definizione** Un albero binario è detto completo se ogni livello ha il massimo numero possibile di nodi.

**Definizione** Un albero binario è detto quasi completo se tutti i livelli sono pieni ma l'ultimo solo in parte (da sinistra a destra).

#### Rappresentazione in memoria

Ci sono 3 possibilità per memorizzare un albero binario:

#### 1. Con record e puntatori

Un nodo è formato dal campo chiave e 2 puntatori ai figli.

#### 2. Posizionale

Si usa un array con la radice in posizione 0, i figli di un nodo all'indice i saranno in posizione 2i, 2i - 1.

#### 3. Vettore dei padri

Si usa un vettore in cui l'indice i corrisponde al nodo i e contiene l'indice del padre di i.

#### Visita dei nodi

Accedere a tutti i nodi risulta leggermente più complicato delle altre strutture, i possibili modi per visitare tutti i nodi sono 3:

#### 1. Preorder

Prima visito il nodo e poi i sottoalberi.

#### 2. Inorder

Visito il sottoalbero sinistro, il nodo e poi il sottoalbero destro.

#### 3. Postorder

Il nodo è visitato dopo le visite ai sottoalberi.

Nel caso in cui si usino i puntatori l'opzione migliore è usare una funzione ricorsiva, indipendentemente dal tipo di visita il costo è  $\Theta(n)$ .

#### 3.6.2 Heap

**Definizione** Un Max-Heap è un albero binario completo (o quasi) con la seguente caratteristica: ogni chiave di un nodo è più grande delle chiavi dei suoi discendenti, ovviamente esiste anche il Min-Heap con la caratteristica opposta.

Data la loro struttura risulta evidente che trovare il massimo/minimo ha costo  $\Theta(1)$  essendo esso la radice.

#### 3.6.3 ABR

**Definizione** Un albero binario di ricerca è un albero binario con la seguente caratteristica:

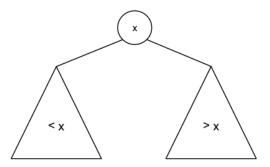


Figura 5: Struttura ABR

Il costo delle operazioni dipende dal bilanciamento dell'albero:

#### • Caso peggiore:

Se l'albero è degenere (graficamente si immagini una diagonale) potrebbe essere necessario scorrerlo interamente, quindi O(n).

#### • Caso migliore:

Se l'albero è completo diventa simile ad una ricerca binaria, il costo è  $\Omega(\log n)$ .

#### 3.6.4 Rosso-nero

**Definizione** Una foglia fittizia è una foglia senza valore che viene eventualmente aggiunta ad un nodo per fargli avere 2 figli.

Definizione Un albero-RB è un ABR con le seguenti caratteristiche:

- I nodi hanno un campo aggiuntivo che contiene il loro colore (Rosso o nero)
- Un nodo rosso ha entrambi i figli neri
- Ogni foglia fittizia è nera
- La radice è nera
- Ogni cammino da un nodo ad una sua foglia discendente contiene lo stesso numero di nodi neri, il numero di nodi neri si indica con b-altezza

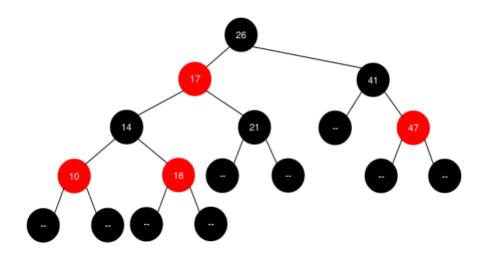


Figura 6: Esempio di albero RB

Queste caratteristiche permettono di avere un albero la cui altezza è sempre:

 $h \leq 2\log(n+1)$  con n nodi interni

#### Rotazione

Questo albero ha una particolare operazione detta rotazione (a DX o SX) che gli permette di mantenere le caratteristiche dopo un inserimento o cancellazione in  $O(\log n)$ .

Nello specifico la rotazione a SX di un nodo x consiste in:

- 1. Il sottoalbero sinistro del figlio destro di x diventa il sottoalbero destro di x
- 2. x diventa il figlio sinistro del suo figlio destro

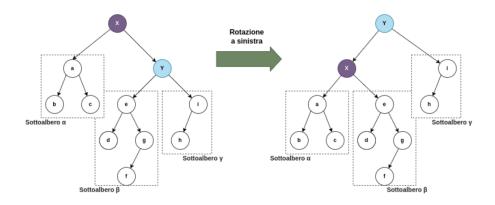


Figura 7: Esempio di rotazione a SX

#### 3.7 Dizionario

**Definizione** Un dizionario è una struttura dati che permette di gestire un insieme dinamico di dati (normalmente ordinato) con 3 sole operazioni:

- Inserisci
- Cancella
- Cerca

Da qui in poi:

- $\bullet$  U = insieme dei valori delle chiavi
- $\bullet$  n = numero di elementi da memorizzare
- $\bullet \ m=$ numero di posizioni disponibili

#### 3.7.1 Indirizzamento diretto

Ipotizzando  $n \leq |U| = m$  basta un array con m posizioni che permette di avere le operazioni con costo  $\Theta(1)$ .

Nella realtà però non è un metodo utilizzabile perché:

- 1. U potrebbe essere enorme
- 2. Le chiavi effettivamente usate potrebbe essere poche e ciò porta ad uno spreco di memoria

#### 3.7.2 Hash

Per risolvere il problema del metodo precedente viene fatto uso di una funzione detta *hash* che fornisce la posizione dove inserire l'elemento in base alla sua chiave.

Le 3 funzioni più comuni sono:

• Scansione lineare:

$$h(k,i) = (h'(k) + i) \mod m \text{ con } i \in [0, m-1]$$

• Scansione quadratica:

$$h(k,i) = (h'(k) + c_1 i + c_2 i^2) \mod m \text{ con } i \in [0, m-1]$$

• Hashing doppio:

$$h(k,i) = (h_1(k) + h_2(k)i) \mod m \text{ con } i \in [0, m-1]$$

Anche questo metodo ha un problema, bisogna trovare una funzione per cui un'eventuale collisione (la funzione dà una posizione già occupata) avvenga con la probabilità più bassa possibile.

#### Risoluzione delle collisioni

Ci sono 2 metodi per affrontare il problema:

- 1. Liste di trabocco
  - Essenzialmente viene associata una lista ad ogni possibile output della funzione, mediamente il costo di ricerca/cancellazione diventa  $\Theta(1 + \frac{n}{m})$ .
- 2. Indirizzamento aperto

Nella funzione si tiene conto anche del numero di collisioni incontrate  $h(k,0), h(k,1), \ldots$ , bisogna però gestire la cancellazione che lasciando una casella vuota può portare a risultati errati nella ricerca.